

MAP - Charting Student Math Misunderstandings

第六組期末專題報告

A1三 B1228006鄭暉薰 A1三 B1228010李怡萱

A1三 B1228011劉姮廷 A1三 B1228021邱庭俞

競賽核心與任務

• 任務定義

- 模型需對每筆學生紀錄完成以下三個層次的判斷：
 - i. 是否選對答案 (True / False)
 - ii. 解釋是否包含誤解 (Correct / Misconception / Neither)
 - iii. 若有誤解，具體屬於哪一類 (例如 Incomplete、Additive ...)
- 上述三層判斷會合併為一個複合標籤，每筆預測最多可輸出 3 個候選標籤，由模型自信度排序。

• 評估指標

- 採用 MAP@3，模型需預測 3 個候選標籤，正解排名越前得分越高。

數據集介紹




1. 資料集：MAP - Charting Student Math Misunderstandings

2. 資料檔案

- train.csv、test.csv 與 sample_submission.csv
- 訓練集約 36,000 筆，測試集 (re-run) 約 16,000 筆

3. 每筆資料包括以下欄位：

欄位名稱	說明	備註
QuestionId	題目唯一識別碼	用於分組切分以避免資料洩漏
QuestionText	題目文字 (數學表達式經人工輔助 OCR 處理)	
MC_Answer	學生選擇的多選答案	
StudentExplanation	學生對該選項的文字解釋	本專題的核心輸入
Category	答案正確性與是否含誤解的組合	僅 train 提供，6 種類別
Misconception	具體誤解名稱	僅 train 提供，無誤解時為 NA




• LABEL 長尾

- 最多 LABEL 的計數 = 14802
- 最少 LABEL 的計數 = 1
- 只有 1 筆的 LABEL 數 = 5

• 發現數據不平衡 → 實作

WeightedTrainer, 對類別頻率反向加權, 上限 10 倍、下限 0.5 倍, 防止極端不平衡。



- 發現到在資料集中特定的數學題目 (QuestionId) 與特定的錯誤邏輯 (Misconception) 有很強的綁定關係
- 為了避免模型作弊 → 使用了 GroupKFold (依 QuestionId 分群) 避免資料洩漏

過去進度及成果

DEBERTA 純分類架構設計

訓練端 (Colab/Local)

- 輸入：QuestionText + MC_Answer + StudentExplanation 拼接
- 標籤：65 類扁平標籤 (Category: Misconception) 例如: True_Correct: NA
- 模型：DeBERTa → CLS token → 自訂分類頭 → 65 類機率
- 類別不平衡：WeightedTrainer 反向加權 ($0.5\times \sim 10\times$)
- 切分：GroupKFold (依 QuestionId, 5-fold)

推論端 (Kaggle)

- 載入 5 個 fold checkpoint
- 各自預測 → 5 個機率矩陣取平均 (Ensemble)
- 取 Top-3 label → submission.csv

技術細節 - 訓練設定


超參數	值
Max length	256
Batch size	16
Learning rate	2e-5
Warmup ratio	0.1
Weight decay	0.01
評估指標	MAP@3
Fold 方式	GroupKFold × 5

4 個版本的設計演進





版本	核心改動	說明
train(4)_first	StratifiedKFold	最原始版
train(4)_new	改 GroupKFold + Cosine early stop	修正資料洩漏 + 新增模擬 LB
train(4)_base	優化 VRAM 使用 + gradient accumulation	同樣 base 架構，解決記憶體問題。 (VRAM 快滿，但 GPU 功耗很低)
train(4)_large	換 DeBERTa-v3-large	模型升級

實驗結果對比

版本	CV MAP @ 3	模擬 LB	Kaggle Public	Kaggle Private	說明
train(4)_first	0.891 (Stratified)	無	0.89457	0.89448	StratifiedKFold
train(4)_new	0.3213 (GroupKFold) ↓	0.9051	0.89397 ↓	0.89433 ↓	修正洩漏， 模擬 LB
train(4)_base	0.3777 (GroupKFold)	0.889	0.88069	0.87859	VRAM 優化版
train(4)_large	0.2925 (GroupKFold)	0.9351 ↑	0.91924 ↑	0.91107 ↑	升級 large









train_4_large.ipynb




超參數調整



版本	改動	CV MAP@3	模擬 LB	Kaggle Public	Kaggle Private
large(基準)	LR=2e-5, MaxLen=256	0.2925	0.9351	0.91924	0.91107
train(4)_lr	LR=1e-5, MaxLen=256	0.3736	0.895↓	0.88747↓	0.88728↓
train(4)_maxlen	LR=2e-5, MaxLen=512	0.3198	0.9346	0.91795	0.91261
MaxLen=512 + Logit Ensemble	同上, 改推論策略	0.3198	0.9346	0.93081↑	0.92442↑



Per-label MAP @ 3 的 fold 分布熱力圖



混淆矩陣



平均預測機率圖

模型預測案例分析

	Row 0	Row 1	Row 2
題目	陰影部分面積	陰影部分面積	哪個數最大
學生答案	$\frac{1}{3}$ ✓	$\frac{3}{6}$ ✗	6.2 ✓
學生解釋	$\frac{1}{3}$ 是 $\frac{3}{9}$ 的最簡分數	3 個白三角、6 個藍三角	因為 2 讓它比較大
模型 Top-1	True_Correct:NA	False_Misconception:WNB	True_Neither:NA
信心度	0.773 (高)	0.750 (高)	0.505 (低)
結果	正確	正確	不確定

ANCHOR+微調模型

Local Anchor

當題目出現在訓練集



同題目 + 同 Misconception 取平均

Global Anchor

未見過的題目



同 Misconception 跨所有題目取平均

BGE 模型微調

同題目 × 同 Misconception 的學生兩兩配對 → 9,821 筆正例

Loss: MultipleNegativesRankingLoss (Batch 內其他樣本自動為負例)

ANCHOR+微調模型

融合公式_1:

$$\text{final_score} = \text{deberta_weight} \times P_DeBERTa + (1 - \text{deberta_weight}) \times (\text{cat_p} \times \text{sim}^2)$$

融合公式_2:

$$\text{final_score} = P_DeBERTa \times (1 + 0.20 \times \text{sim}^2)$$

cat_p = Category Probability

ANCHOR+微調模型

整體流程

Fine-tuned BGE

▼ encode

學生解釋的向量

▼ cosine similarity

Anchor 向量

(每種 Misconception 的代表)



當DeBERTa信心度低於90 % 才會融合分數 → Top-3 輸出

實驗結果總結

 notebookda7d0a18fa (3) - 1.0 Succeeded (after deadline) · 2d ago · Notebook notebookda7d0a18fa (3) Version 18	0.89771	0.90084	☐
 notebookd1a81ec8f1 - 0.0 Succeeded (after deadline) · 19m ago · Notebook notebookd1a81ec8f1 Version 3	0.80187	0.80502	☐
 notebookd1a81ec8f1 - mix Succeeded (after deadline) · 18m ago · Notebook notebookd1a81ec8f1 Version 1	0.89795	0.90061	☐
 notebook6744a06128 - 7 Succeeded (after deadline) · 1d ago · Notebook notebook6744a06128 Version 5	0.89786	0.90054	☐

方法	Kaggle Public LB
DeBERTa-v3-base (純分類)	0.90084
Anchor+微調模型 (純檢索)	0.80502
DeBERTa + BGE Anchor 融合	0.90061
DeBERTa + BGE Anchor 加權	0.90054

實驗結果總結

方法	Kaggle Public LB
DeBERTa-v3-base (純分類)	0.90084
Anchor+微調模型 (純檢索)	0.80502
DeBERTa + BGE Anchor 融合	0.90061
DeBERTa + BGE Anchor 加權	0.90054

「純 DEBERTA (0.90084)」 的分數其實高於 「融合模型 (0.90061)」 與 「加權模型 (0.90054)」 。

發現： **引入 BGE 檢索分數反而導致 PUBLIC LB 退步。**

分析BGE檢索

BGE 檢索的結構性天花板

```
=====
BGE 檢索 (Recall@K
=====
```

```
有效評估樣本數： 9860 筆
```

```
Recall@1 : 71.90%
```

```
Recall@3 : 99.94%
```

```
Recall@5 : 100.00%
=====
```

1. BGE 能抓出迷思， 但有近 3 成機率在第一順位給出錯誤判斷。
2. 擅長限縮範圍， 卻極度不擅長做最終決定。

鑑別度喪失

=====

題目 ID: 31772

題目內容: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A triangle split into 9 equal smaller triangles. 6 of them are shaded.]

學生選項: $\frac{1}{3}$

學生解釋: I think that 1/3 is the answer, as it's the simplest form of 3/9.

Local Anchor

BGE 檢索 Top-5 相似錯誤概念:

- | | | | |
|-----|-------------|--|----------------|
| [1] | 相似度: 0.5928 | | 標籤: NA |
| [2] | 相似度: 0.5911 | | 標籤: Incomplete |
| [3] | 相似度: 0.5758 | | 標籤: WNB |
- =====

面對正確選項 (QID 31772)

TOP-1 與 TOP-2 的相似度差距僅 0.0017。

表面詞彙匹配

=====

題目 ID: 31772

題目內容: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A triangle split into 9 equal smaller triangles. 6 of them are shaded.]

學生選項: $\frac{3}{6}$

學生解釋: i think this answer is because 3 triangles are white and 6 triangle are blue.

=====

Local Anchor

BGE 檢索 Top-5 相似錯誤概念:

- [1] 相似度: 0.5900 | 標籤: WNB
 - [2] 相似度: 0.5787 | 標籤: NA
 - [3] 相似度: 0.5732 | 標籤: Incomplete
- =====

學生將「部分比部分」搞錯（3白比6藍），BGE 卻因字面重疊，優先推播無關的「整數偏誤 (WNB)」。

邏輯矛盾盲區

=====

題目 ID: 32835

題目內容: Which number is the greatest?

學生選項: \ (6.2)

學生解釋: because the 2 makes it higher than the others.

Local Anchor

BGE 檢索 Top-5 相似錯誤概念:

- | | | | |
|-----|-------------|--|--------------------------|
| [1] | 相似度: 0.6276 | | 標籤: NA |
| [2] | 相似度: 0.6228 | | 標籤: Longer_is_bigger |
| [3] | 相似度: 0.6164 | | 標籤: Shorter_is_bigger |
| [4] | 相似度: 0.6150 | | 標籤: Ignores_zeroes |
| [5] | 相似度: 0.5992 | | 標籤: Whole_numbers_larger |
- =====

遇到小數比大小，「越長越大」與「越短越大」兩個邏輯完全相反的標籤，竟獲得幾乎相同的極高分 (~0.62)。

結論

```
=====
BGE 檢索 (Recall@K
=====
```

```
有效評估樣本數： 9860 筆
```

```
Recall@1 : 71.90%
```

```
Recall@3 : 99.94%
```

```
Recall@5 : 100.00%
=====
```

為了避免 BGE 高達 28.1 % 的 TOP-1 誤判率 (100 % - 71.9 %)

放棄 BGE 檢索

回歸純 DEBERTA 的深度交叉比對

最新進度及成果

推論流程優化方向

改動項目	說明	目的
Logit Ensemble	不再先把每個 fold 轉成機率後平均， 而是先平均 logits，再做 softmax	保留模型原始信心差距， 避免機率平均把高信心預測壓平
Soft Family Constraint	根據同一題常見的合法 label 範圍， 對可能 label 加分、對不常見 label 降分	利用題目本身的 label 分布， 減少不合理預測
is_correct Gate	根據學生選項是否為正確答案， 強化 True_* 或 False_* 類別	避免正確選項預測成 False_*, 或錯誤選項預測成 True_*
QuestionId + MC_Answer Prior	根據「題目 + 學生選項」 建立更細的候選 label prior	同一題不同選項常對應不同迷思， 能輔助排序
True/False Hard Gate	最後直接過濾掉與選項正確性不一致的 類別	進一步避免不合理類別進入 Top-3

推論調參消融實驗總表

階段	版本	推論策略	Public	結論
Baseline	V091 + A	原始 DeBERTa, 機率平均, 無後處理	0.91924	原始基準
+ Family Constraint	V091 + B	加入 soft Family Constraint	0.92053	小幅提升, 代表題目層級規則有效
+ Logit Ensemble	L-B	改用 Logit Ensemble + soft Family Constraint	0.92868	大幅提升, 是主要加分來源
+ QA Prior	L-QA	L-B + QuestionId + MC_Answer prior	0.92872	幫助很小
+ is_correct Gate	L-IC	L-B + is_correct gate	0.92944	明顯提升, 是第二大加分來源
Combined	MAX1	L-B + is_correct gate + QA prior	0.92953	當時最佳, QA 有微幅輔助

後處理參數加強實驗

版本	調整內容	Public	結論
MAX2	強化 is_correct + 保留原 QA	0.92953	比 MAX1 略高
MAX3	更強化 is_correct + 保留原 QA	0.92948	過度加強後略降
MAX4	強化 is_correct + 不用 QA	0.92948	QA 關掉後沒有更好
P-QA1	強化 is_correct + 弱化 QA	0.93166	明顯提升
P-QA2	更強 is_correct + 弱化 QA	0.93166	與 P-QA1 幾乎相同
P-IC1	強化 is_correct, 不使用 QA	0.93166	QA 有微幅幫助, 但不是主因
BOLD-A	大幅強化 True/False gate, 不使用 QA	0.93170	本輪最佳
BOLD-B	大幅強化 True/False gate + family 調整	0.93166	沒有超過 BOLD-A

這裡有換一個最高分的新模型, 但兩個模型分數差異沒有很大

TRUE / FALSE HARD GATE 實驗

版本	調整內容	Public	結論
TF-HARD-A	True/False hard gate, 不使用 QA	0.93179	Public 提升, 但 Private 未超過最佳
TF-HARD-QA	True/False hard gate + 弱 QA	0.93183	QA 有小幅幫助
TF-HARD-QA2	True/False hard gate + 原 QA	0.93187	目前最佳版本
FAM-STR1	Semi hard gate + 加強 Family Constraint	0.93183	有幫助但不如 TF-HARD-QA2
FAM-STR2	Semi hard gate + QA + 加強 Family Constraint	0.93183	接近最佳, 但仍略低

消融實驗重點結論

發現	證據	解釋
Logit Ensemble 是最大提升來源	V091+B: 0.91223 → L-B: 0.92321	比單純機率平均更能保留模型信心， 提升最明顯
is_correct gate 是第二大提升來源	L-B: 0.92321 → L-1C: 0.92404	選項是否正確與 True/False 類別高度相關
QA prior 有幫助，但幅度小	L-1C: 0.92404 → MAX1: 0.92416	QuestionId + MC_Answer prior 只能微幅調整排序
過度微調規則效果有限	多個 P 系列 都約 0.92528 / 0.93166	多數版本 top-3 改動有限， 進入瓶頸
Hard True/False gate 最佳	TF-HARD-QA2: 0.92537 / 0.93187	錯誤 True/False 類別不應進入 Top-3， 硬過濾有效

目前最佳推論版本

項目	設定
模型	DeBERTa-v3-large 5 folds
Ensemble	Logit Ensemble
Family Constraint	使用 soft Family Constraint
is_correct	使用 True / False hard gate
QA Prior	使用 QuestionId + MC_Answer prior
Private Score	0.92537
Public Score	0.93187

目前最佳推論版本

項目	設定
模型	DeBERTa-v3-large 5 folds
Fami Constr	
QA Prior	使用 QuestionId + MC_Answer prior
Private Score	0.92537
Public Score	0.93187

目前單純推論後處理已能有效提升分數，

但後續增益逐漸變小，

因此需要嘗試更進一步的二階段架構。

為什麼加入 RERANKER?

目前推論規則主要能修正：

- TRUE / FALSE 類別錯誤
- QUESTIONID 不合理 LABEL
- MC_ANSWER 對應的常見 MISCONCEPTION

但若模型已經把正確答案放在 TOP-10，卻沒有排進 TOP-3，
單純規則不一定能救回來。

因此我們加入 **RERANKER**：

- 第一階段：主模型產生 TOP-K 候選 LABEL
- 第二階段：RERANKER 重新判斷每個候選是否符合學生解釋
- 最後：融合 FIRST-STAGE SCORE 與 RERANKER SCORE，重新排序 TOP-3

RERANKER 方法說明

階段	做法	目的
第一階段	使用目前最佳 DeBERTa 模型產生 Top-K candidates	確保正確 label 進入候選集合
第二階段	將每個 candidate label 與學生解釋配對輸入 reranker	判斷候選 label 是否真的符合學生解釋
分數融合	$\text{final_score} = \text{first-stage score} + \text{reranker score}$	保留主模型信心，同時利用 reranker 微調排序
最終輸出	重新排序後取 Top-3	提升 MAP@3

RERANKER 的輸入設計

每一筆候選會被轉成一個二元判斷任務：

- QUESTION:{QUESTIONTEXT}
- STUDENT SELECTED ANSWER:{MC_ANSWER}
- IS SELECTED ANSWER CORRECT:是 / 否
- STUDENT EXPLANATION:{STUDENTEXPLANATION}
- CANDIDATE CATEGORY:{CATEGORY}
- CANDIDATE MISCONCEPTION:{MISCONCEPTION}
- DOES THIS CANDIDATE MATCH THE STUDENT'S REASONING?

模型任務：

- 輸出 1: CANDIDATE 符合學生解釋
- 輸出 0: CANDIDATE 不符合學生解釋

RERANKER 訓練設定

項目	設定
第一階段模型	DeBERTa-v3-large 5-fold logits ensemble
候選產生	使用 TF-HARD-QA2 後處理後產生 Top-K candidates
訓練資料格式	每筆資料轉為多個 candidate pair
正樣本	candidate label = 真實 label
負樣本	first-stage Top-K 中錯誤但相近的 hard negatives
任務形式	Binary classification: 判斷 candidate 是否符合學生解釋
輸入長度	Max length 384
訓練策略	使用 hard negatives 強化相近 misconception 的區分能力
分數融合	first-stage score 與 reranker score 加權融合

RERANKER 初步實驗結果

版本	First-stage 權重	Reranker 權重	Public	結論
Baseline	1.00	0.00	0.92991	不使用 reranker
R-0.80	0.80	0.20	0.93027	reranker 權重偏高
R-0.90	0.90	0.10	0.93136	輕度融合
R-0.95	0.95	0.05	0.93231	目前最佳 reranker 融合版本

皆有加入TF-HARD-QA2之參數

目前最佳分數

版本	Private	Public
TF-HARD-QA2	0.92537	0.93187
TF-HARD-QA2 + R-0.95	0.92541	0.93231



notebook5d89c2be4e - TF-HARD-QA2

Succeeded (after deadline) · 6d ago

0.92537

0.93187



notebook985a857023 - R-0.95

Succeeded (after deadline) · 4d ago

0.92541

0.93231



後續方向

1. 訓練更強 RERANKER, 提高候選排序能力

- 增加 TOP-K CANDIDATES
- 增加訓練 EPOCH

2. 增加 HARD NEGATIVE 數量, 讓 RERANKER 學會區分相近
MISCONCEPTION

3. 測試更保守的融合比例, 如 R-0.97、R-0.95

未來規劃


週次	里程碑	預計產出
Week 15	報告+書面報告撰寫; 訓練更強 reranker+測試	報告週
Week 16	書面報告定稿; 程式碼整理	Word 書面報告; GitHub repo 完整版

分工表

組員	角色
李怡萱	資料分析 / Baseline
鄭暉薰	Transformer 模型
邱庭俞	檢索與 RAG
劉姮廷	最終調整與整合

參考資料

- FAMILY CONSTRAINT
- WEIGHTEDTRAINER 與 CLASS WEIGHTS
- IS_CORRECT 特徵工程與 PROMPT 語意轉換



謝謝大家聆聽！